Nama Kelompok	Predict - 7B
Identitas Anggota	Gusti Ngurah Satya Bagus Partama
Kelompok	Abdullah Sholdan Rona
	Roby Sabililhaq
	Ramzy Al Firza Wahyudi
	Aloysius No
	Fatin Nu'maya
	Tasya Amalia Dewi
	Rifa Husniyyah

1. Descriptive Statistics

a. Apakah ada kolom dengan tipe data kurang sesuai, atau nama kolom dan isinya kurang sesuai?

Melihat setiap *variable*, diberikan kesimpulan bahwa **pada** *dataset* **tidak ditemukan kolom/variable yang memiliki nama kolom, tipe data serta isi kolom yang kurang sesuai.** Pemisahan kategorikal dengan numerikal juga sudah sangat jelas, dan sudah masuk akal.

Akan tetapi, salah satu kolom yang dapat dibuat dalam bentuk yang lebih baik adalah kolom *balance*. Hal ini dikarenakan sifat *balance* yang seharusnya diizinkan untuk bernilai *float* (memiliki koma) atau kontinu. Namun, dalam *dataset* disajikan dalam bentuk *integer* atau diskret.

Kategorikal Ord	inal defaul	lt, month,	loan,	housing,	education,	У
-----------------	-------------	------------	-------	----------	------------	---

	Nominal	marital, job, contact, poutcome
Numerical	Discrete	age, balance, day, duration, campaign, pdays, previous

b. Apakah ada kolom yang memiliki nilai kosong? (missing-values)

Tidak ada column yang memiliki nilai kosong (null-values), namun ada nilai yang diganti menjadi nilai *other* dan *unknown*. Nilai *other* terlihat pada kolom poutcome selain itu terdapat juga nilai *unknown* yang terlihat pada kolom contact.

c. Apakah ada kolom yang memiliki nilai summary agak aneh? (min/mean/median/max/unique/top/freq)

Variable balance memiliki nilai summary yang agak aneh.		balance	
Hal ini terlihat dari nilai minimum balance yang		45211	
menunjukan angka minus. Anehnya setelah ditelusuri lebih			
jauh, ternyata ada persentase customer dengan balance	mean	1362.27	
negative yang menerima tawaran term deposit bank.	std	3044.76	
Hipotesis yang dapat diberikan terhadap <i>customer</i> dengan	min	-8019	
balance <i>negative</i> adalah bahwa beberapa <i>customer</i>		72	
mengikuti program overdraft. [1] [2] [3]	50%	448	
Mean & Median balance juga terpaut angka yang sangat	75%	1428	
jauh sehingga dapat diindikasi bahwa variable memiliki	max	102127	
outlier.			
Variable previous memiliki nilai summary yang agak aneh.		previous	
Hal ini terlihat dari nilai kuartil 1 hingga 3 dan minimum yang menunjukan angka yang sama yaitu 0. Hal ini	count	45211	
mengindikasi bahwa dari nilai terendah hingga 75% data	mean	0.58	

Hal ini sebenarnya sejalan dengan variabel pdays, &		
terhadap <i>customer</i> tidak memiliki nilai yang diketahui pasti.		
adalah bahwa kebanyakan hasil dari <i>campaign</i> sebelumnya	freq	36959
Kesimpulan yang bisa diberikan atas kondisi sebaran ini	top	unknown
yang dapat diindikasi sebagai treated missing values.	unique	4
diawali dengan <i>top-value</i> yang menunjukan nilai <i>unknown</i>	count	45211
Variable outcome memiliki tipe data categorical dan dari summaries nya memiliki nilai yang agak aneh. Keanehan	poutcom	Γ
	max	871
dengan jangka wakta setama 671 man.	75%	-1
kondisi yang sangat <i>special</i> dan dihubungi terakhir kali dengan jangka waktu selama 871 hari.	50%	-1
tailed di kanan dan dipastikan memiliki outlier dengan	25%	-1
Kondisi distribusi juga dapat dibayangkan memiliki long	min	-1
terakhir dihubungi -1.	std	100.128
pernah dikontak sebelumnya sehingga memiliki nilai hari	mean	40.197
ini mirip dengan kondisi <i>previous</i> dimana 75% datanya terdiri atas nilai -1 yang mengindikasi 75% <i>customer</i> belum	count	45211
Varibale pday memiliki nilai summary yang agak aneh. Hal	pday	
kanan.	max	275
dengan kondisi nilai maksimum yaitu 275 dapat dipastikan bahwa <i>variable</i> memiliki <i>outlier</i> dan <i>long tailed</i> di bagian	75%	0
Meskipun <i>mean & median variable</i> tidak terpaut jauh,	50%	0
di kontak pada <i>campaign</i> sebelumnya.	25%	0
75% <i>customer</i> merupakan <i>customer</i> baru yang belum pernah	min	0
terdiri atas nilai 0. Nilai ini menunjukan bahwa sebanyak	std	2.3

previous yang mengindikasi bahwa 75% *customer* yang dihubungi merupakan *customer* baru yang belum pernah ditawarkan *promosi* sebelumnya.

2. Univariate Analysis

	Numerical Column Analysis
Age	Variabel memiliki distribusi <i>positive-skewed</i> atau <i>right-skewed</i> .
	Distribusi yang skewed menyebabkan variable memiliki outlier,
	yang apabila dilihat berdasarkan maksimum IQR threshold
	terdeteksi berada di nilai Age lebih dari 70 tahun.
	- Mean : 40.93
	- Median : 39.00
	- Min : 18.00
	- Max : 95.00
	Melihat anomali data yang mengandung outlier berdasarkan
	analisis IQR, hipotesis yang dapat diberikan dari keadaan ini
	adalah randomness yang diberlakukan saat memilih customer
	sebagai target market.
	Sebaran nilai minimum dan maksimum data berdasarkan usia
	apabila dilihat dari sudut pandang usia masih masuk akal karena
	memang dapat saja terdapat customer dengan umur mencapai nila
	maksimum.
	- Modus : 32.00
	- Kuartil 1 : 33.00
	- Kuartil 3 : 48.00
Balance	Saldo rata-rata tahunan (dalam euro) menunjukkan lebih banyak
	outlier di atas upper bound daripada dibawah lower bound,

menyebabkan **boxplot yang berimpit**, menunjukkan pola sebaran data yang s**angat condong ke kanan dan tidak norma**l.

Persebaran data pada variabel balance yaitu:

- Min : -8019

- Mean : 1362.27

- Kuartil 1 : 72

- Median : 448

- Kuartil 3 : 1428

- Max : 102127

Melihat visualisasi persebaran data dan summary variabel, saldo rata-rata cukup **variatif dan tidak merata**. Perolehan nilai minimum dan maksimum memiliki s**elisih yang cukup jauh.** Selain itu, nilai minimum memiliki angka negatif menunjukan keanehan karena saldo rata-rata tahunan umumnya tidak mencapai nilai negatif.

Day

Variabel day memiliki distribusi normal dan pola persebaran yang simetris. Selain itu, tidak ditemukan nilai outlier dari data kontak terakhir yang dihubungi dalam sebulan. Dengan persebaran data variabel day yaitu:

- Min : 1

- Mean : 15.8

- Kuartil 1 : 8

Median : 16

- Kuartil 3 : 21

- Max : 31

Perolehan nilai persebaran data menunjukan nilai yang normal dengan nilai pada interval 1 - 31 dan rata-rata 15.8 yang tidak berbeda jauh dengan median 16.

Duration

Durasi kontak terakhir (detik) memiliki banyak data outlier di

atas upper bound, artinya terdapat durasi kontak yang cukup lama dibandingkan yang lainnya. Hal ini menyebabkan Positively Skewed Boxplot yang sangat berhimpit. Persebaran data pada variabel duration yaitu:

- Min : 0

- Mean : 258.2 - Kuartil 1 : 103 - Median : 180 - Kuartil 3 : 319

Max

Hasil visualisasi dan summary persebaran data duration, menunjukkan bahwa durasi kontak terakhir (detik) memiliki **persebaran yang tidak merata** karena ditemukan nilai minimum **0 artinya tidak ada durasi** pada kontak terakhir sedangkan ditemukan **durasi terlama (max) yaitu 4918**. Selain itu, nilai median dan mean juga memiliki terdapat selisih 78.2.

: 4918

Campaign

Jumlah kontak selama kampanye ini menunjukkan banyak **outlier di atas u**pper bound sehingga pola sebaran yaitu *positive-skewed* **yang berimpit**, artinya menunjukkan ketidakmerataan dalam kontak yang dilakukan.

Persebaran data pada variabel campaign yaitu:

Min : 1
Mean : 2.7
Kuartil 1 : 1
Median : 2
Kuartil 3 : 3
Max : 63

Visualisasi dan ringkasan persebaran data , menunjukan nilai maksimum 63 yang sangat jauh dengan nilai lainnya. Hal ini

	T		
	dapat mempengaruhi perolehan nilai rata-rata dari data yang tidak		
	mewakili data secara keseluruhan. Selain itu, nilai maksimum ini		
	menunjukkan tidak meratanya jumlah kontak yang dilakukan		
	selama kampanye ini dan untuk klien ini.		
Pdays	Jumlah hari yang berlalu setelah klien terakhir dihubungi dari		
	kampanye sebelumnya memiliki outlier yang sangat banyak di		
	atas upper bound sehingga sebaran data positive-skewed yang		
	berimpit. Persebaran data pada variabel pdays yaitu:		
	- Min : -1		
	- Mean : 40.2		
	- Kuartil 1 : -1		
	- Median : -1		
	- Kuartil 3 : -1		
	- Max : 871		
	Visualisasi dan ringkasan persebaran data, menunjukan nilai		
	maksimum 871 yang sangat jauh dengan nilai lainnya yang		
	bernilai -1 dengan artian banyak klien yang belum pernah		
	dihubungi sebelumnya . Hal ini dapat mempengaruhi perolehan		
	nilai rata-rata dari data yang tidak mewakili data secara		
	keseluruhan. Sehingga, bentuk persebaran visualisasi sulit		
	dideteksi.		
Previous	Jumlah kontak sebelum kampanye ini memiliki outlier ekstrim di		
	bagian atas. sehingga sebaran data <i>positive-skewed</i> yang		
	berimpit. Persebaran data pada variabel previous yaitu:		
	- Min : 0		
	- Mean : 23		
	- Kuartil 1 : 0		
	- Median : 0		
	- Kuartil 3 : 0		

- Max : 275

Visualisasi dan ringkasan persebaran data , menunjukan nilai maksimum 275 yang sangat jauh dengan nilai lainnya yang bernilai 0 dengan artian banyak kontak sebelum kampanye belum dilakukan. Hal ini dapat mempengaruhi perolehan nilai rata-rata data yang tidak mewakili data secara keseluruhan. Sehingga, bentuk persebaran visualisasi sulit dideteksi.

Categorical Column Analysis

Pada data kategorikal, kolom default, loan, y, dan poutcome memiliki selisih yang cukup jauh. Khususnya untuk poutcome yang di dominasi oleh data yang tidak diketahui. Selain itu, ditemukan kategori 'unknown' pada variabel job, education, contact, dan poutcome yang memberikan ketidakjelasan data.

Berdasarkan data yang ada, kolom default sebaiknya dihilangkan dan kolom poutcome hanya dikategorikan sebagai sukses atau gagal saja tanpa ada keterangan 'lainnya' dan dilakukan treatment untuk data yang 'unknown'

job	Jenis pekerjaan memiliki 12 kategori dengan jenis pekerjaan			
	paling banyak yaiti	paling banyak yaitu blue collar sebanyak 9732.		
	- Count	: 45211		
	- Unique	: 12		
	- Тор	: blue-collar		
	- Freq	: 9732		
	hasil visualisasi dengan barchart menunjukan frekuensi setiap			
	kategori tidak men	miliki selisih yang jauh.		
marital	Status pernikahan	memiliki 3 kategori (married, single, divorced)		
	dengan status pernikahan paling banyak yaitu married sebanyak			
	27214			

	- Count	: 45211
	- Unique	: 3
	- Тор	: married
	- Freq	: 27214
	Hasil visualisasi deng	gan barchart menunjukan frekuensi setiap
	kategori tidak memi	liki selisih yang jauh.
education	Variabel pendidikan	memiliki 4 kategori (secondary, primary,
	tertiary, dan unknowi	n) dengan pendidikan paling banyak yaitu
	sekunder sebanyak	23202.
	- Count	: 45211
	- Unique	: 4
	- Тор	: secondary
	- Freq	: 23202
	hasil visualisasi deng	an barchart menunjukan frekuensi setiap
	kategori tidak memi	liki selisih yang jauh.
default	Variabel default mem	niliki 2 kategori (yes dan no) dengan
	kreditnya paling bany	yak yaitu no sebanyak 44396.
	- Count	: 45211
	- Unique	: 2
	- Тор	: no
	- Freq	: 44396
	hasil visualisasi deng	an barchart menunjukan frekuensi kedua
	kategori memiliki sel i	isih yang jauh. Sehingga terlalu banyak
	kredit yang berstatus	'no'.
housing	Status kepemilikan p	eminjaman perumahan memiliki 2 kategori
	(yes dan no) dengan	status yes paling banyak yaitu 25130.
	- Count	: 45211

	- Unique	: 2
	- Тор	: yes
	- Freq	: 25130
	hasil visualisasi deng	gan barchart menunjukan frekuensi kedua
	kategori tidak mem i	iliki selisih yang jauh.
loan	Status kepemilikan p	pinjaman pribadi memiliki 2 kategori (yes dan
	no) dengan status no	paling banyak yaitu 37967.
	- Count	: 45211
	- Unique	: 2
	- Тор	: no
	- Freq	: 37967
	hasil visualisasi deng	gan barchart menunjukan frekuensi kedua
	kategori memiliki se	lisih yang jauh.
contact	Jenis komunikasi ko	ntak yang dilakukan memiliki 3 kategori
	(telepon, seluler, dan	'unkown') dengan kategori selular paling
	banyak yaitu 29285	
	- Count	: 45211
	- Unique	: 2
	- Тор	: cellular
	- Freq	: 29285
	hasil visualisasi deng	gan barchart menunjukan frekuensi dari
	cellular terhadap 'un	known' dan telephone memiliki selisih yang
	cukup jauh.	
month	Bulan kontak terakhi	ir dalam setahun memiliki 12 kategori dengan
	may paling banyak	yaitu 13766.
	- Count	: 45211
	- Unique	: 12
1		

	- Freq : 13766
	hasil visualisasi dengan barchart menunjukan frekuensi dari bulan
	may terhadap bulan lainnya memiliki selisih yang cukup jauh.
	Ini artinya, bulan may menjadi bulan terakhir yang memiliki
	kontak terbanyak.
poutcome	Hasil marketing campign memiliki 4 kategori (sukses, gagal,
	lainnya, dan 'unknown') dengan kategori unknown paling
	banyak yaitu 36959.
	- Count : 45211
	- Unique : 4
	- Top : unknown
	- Freq : 36959
	hasil visualisasi dengan barchart menunjukan frequensi dari
	'unknown' memiliki selisih yang sangat jauh dengan 3 kategori
	lain. Keberadaan 'unkonwn' yang banyak menyebabkan hasil
	marketing campign sulit dianalisis, sehingga perlu treatment untuk
	mengatasainya.
у	Status klien yang sudah berlangganan deposito dikategorikan
	menjadi 2 yaitu yes dan no dengan kategori no memiliki
	frekuensi terbanyak yaitu 39922.
	- Count : 45211
	- Unique : 2
	- Top : no
	- Freq : 39922
	hasil visualisasi dengan barchart menunjukan frequensi dari no
	memiliki selisih yang sangat jauh dengan kategori yes. Artinya,
	klien lebih banyak yang belum berlangganan deposito.

3. Multivariate Analysis

a. Bagaimana korelasi antara masing-masing feature dan label. Kira-kira feature mana saja yang paling relevan dan harus dipertahankan?

Korelasi antar variabel tidak ada yang memiliki hubungan yang kuat, namun ada yang memiliki hubungan positif yang cukup sedang yaitu antara variabel pdays dengan previous sebesar 0.45. Dimana jika pdays mengalami kenaikan, maka previous juga meningkat, begitupun sebaliknya. Kemudian disusul oleh hubungan positif antara campaign dan day sebesar 0.16, serta hubungan positif antara age&balance sebesar 0.10. Untuk variabel lainnya memiliki hubungan yang sangat lemah karena mendekati nilai 0, bahkan tidak ada hubungan sama sekali antara variabel duration&previous, age&previous, balance&pdays, age&campaign, duration&age, day&balance.

Feature yang relevan dan perlu dipertahankan yaitu campaign, day, age, dan balance karena perlu di analisa lebih lanjut hubungan antar variabelnya. Sementara itu, untuk pdays dan previous terlalu timpang datanya. Oleh karena itu, disimpulkan bahwa semua fitur relevan namun tidak semua fitur layak dipertahankan.

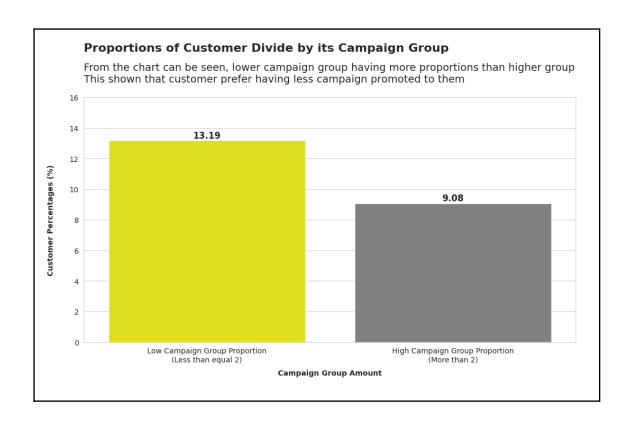
b. Bagaimana korelasi antar-feature, apakah ada pola yang menarik? Apa yang perlu dilakukan terhadap feature itu?

korelasi antar feature cukup menarik karena tidak menunjukkan hubungan linier yang begitu kuat antar variabelnya dan hanya memiliki korelasi tertinggi yaitu 0.45. Hal yang dapat dilakukan untuk fitur ini misalnya eksplorasi lebih lanjut untuk pola non-liniernya, melakukan feature engineering, dan analisis multivariat.

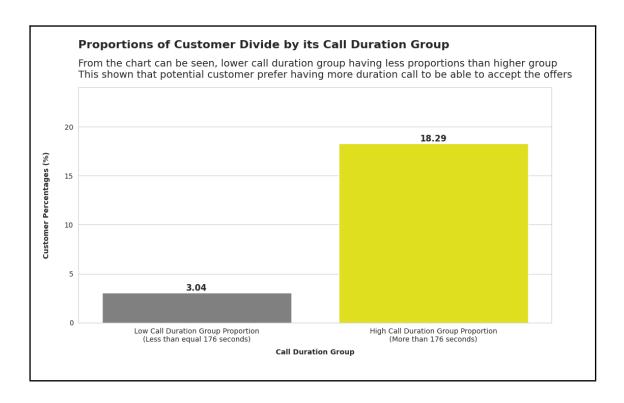
4. Business Insight

Title	Hubungan Jumlah Campaign yang ditawarkan kepada nasabah
	terhadap Conversion Rate

Proses	Hubungan diterapkan menggunakan <i>z-score proportion</i> , data
	menunjukan distribusi yang <i>skewed</i> sehingga diterapkan
	pre-processing melalui z-score normalization.
	Normalisasi diterapkan dalam satu tahapan, namun meskipun
	telah menerapkan normalisasi <i>outlier</i> masih terlihat dalam data.
	Nilai maksimum <i>variable</i> awalnya bernilai lebih dari 60.
	Namun setelah diterapkan nilai maksimum data menjadi 12.
	Hal ini meskipun tidak menghapus seluruh outlier namun telah
	menunjukan representasi yang lebih baik dan lebih masuk akal
	untuk menerapkan <i>campaign</i> dalam batas 12 kali saja. Oleh
	karena itu sekali perform <i>normalisasi</i> dirasa telah cukup untuk
	menghilangkan anomali data.
Findings	Business insight yang didapatkan berdasarkan significance
	testing adalah bahwa jumlah campaign yang pernah diberikan
	terhadap customer berpengaruh terhadap keinginan nasabah
	untuk dapat membuka rekening term deposit. Conversion rate
	terjadi lebih baik pada control group yang merupakan data
	group untuk jumlah campaign yang lebih sedikit (kurang sama
	dengan 2)
Business	Business recommendation yang dapat diberikan berdasarkan
Recommendation	insight ini untuk meningkatkan conversion rate adalah dengan
	membatasi jumlah campaign untuk setiap potential customer
	menjadi paling banyak 2.



Title	Hubungan Durasi Call Marketing kepada nasabah terhadap Conversion Rate
Findings	Business insight yang didapatkan berdasarkan significance testing adalah bahwa durasi call marketing berpengaruh terhadap keinginan nasabah untuk dapat membuka rekening term deposit. Conversion rate terjadi lebih baik pada treatment group yang merupakan data group untuk call duration yang lebih lama (lebih dari 176 detik)
Business Recommendation	Business recommendation yang dapat diberikan berdasarkan insight ini untuk meningkatkan conversion rate adalah dengan meningkatkan call duration untuk setiap potential customer menjadi setidaknya selama 176 detik.



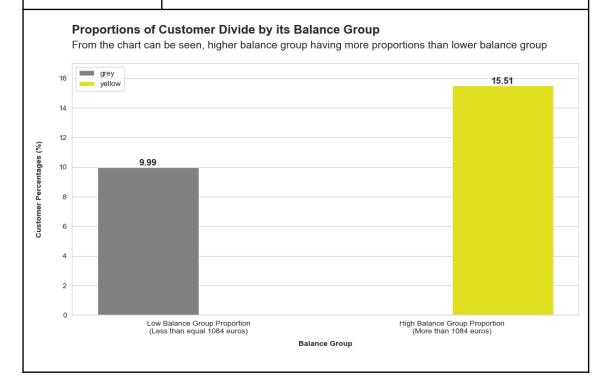
Title	Hubungan Kelompok Umur Nasabah terhadap Conversion Rate
Findings	Business insight yang didapatkan berdasarkan significance testing adalah bahwa jumlah kelompok umur customer berpengaruh terhadap keinginan nasabah untuk dapat membuka rekening term deposit. Conversion rate terjadi lebih baik pada treatment group yang merupakan data group untuk jumlah kelompok kelompok umur di bawah sama dengan 20.
Business Recommendation	Business recomendation yang dapat diberikan berdasarkan insight ini untuk meningkatkan conversion rate adalah dengan menghubungi kelompok umur yang di bawah sama dengan 20.

Title	Hubungan Kelompok <i>Balance</i> Nasabah terhadap <i>Conversion Rate</i>
Findings	Business insight yang didapatkan berdasarkan significance

testing adalah bahwa jumlah kelompok balance customer berpengaruh terhadap keinginan nasabah untuk dapat membuka rekening term deposit. Conversion rate terjadi lebih baik pada treatment group yang merupakan data group untuk jumlah kelompok balance diatas rata-rata (kurang sama dengan 1084 euro)

Business Recommendation

Business recomendation yang dapat diberikan berdasarkan insight ini untuk meningkatkan conversion rate adalah dengan **menghubungi kelompok balance yang diatas rata-rata.**



Title	Hubungan last day contacted of the month terhadap Conversion rate
Findings	Business insight yang didapatkan berdasarkan significance testing adalah bahwa jumlah hari dihubungi berpengaruh terhadap keinginan nasabah untuk dapat membuka rekening

	term deposit. Conversion rate terjadi lebih baik pada treatment group yang merupakan data group untuk customer yang dihubungi pada rentang yang lebih cepat (kurang dari 15 hari)
Business Recommendation	Business recomendation yang dapat diberikan berdasarkan insight ini untuk meningkatkan conversion rate adalah dengan membuat durasi contact terakhir, lebih pendek maksimal 15 hari
From the chart car	acted on longer than 15 days having better conversion rate yellow grey
Customer Percentages (%) 9 10 11	10.49

Title	Hubungan jumlah kontak yang pernah dijalankan pada campaign sebelumnya terhadap Conversion Rate
Findings	Business insight yang didapatkan berdasarkan significance testing adalah bahwa jumlah kontak pada campaign sebelumnya berpengaruh terhadap keinginan nasabah untuk dapat membuka

Last Days Contacted

High Contacted Days (More than 15 days)

Low Contacted Days (less than equal to 15 days)

		rekening <i>term deposit</i> . <i>Conversion rate</i> terjadi lebih baik pada <i>treatment group</i> yang merupakan data group untuk customer yang pernah di kontak (lebih dari 0).
Recommendation insight ini untul meningkatkan e		Business recommendation yang dapat diberikan berdasarkan insight ini untuk meningkatkan conversion rate adalah dengan meningkatkan engagement kepada customer melalui kontak customer setidaknya sekali dalam satu campaign.
	Proportions of Customer Divide by Amount of Contacted on Previous Campaign From the chart can be seen, customer that contacted on previous campaign having better conversion rate	
Customer Percentages (%)	20	22.96
Custome	5	9.16
	0	Not Contacted Contacted (equal to 0) (More than 0)

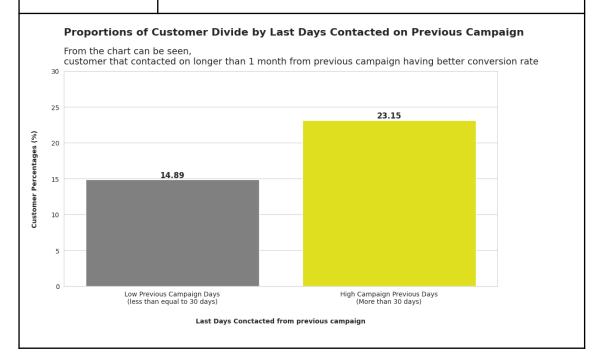
Title	Hubungan <i>last day contacted of the month</i> yang pernah dijalankan pada <i>campaign</i> sebelumnya terhadap <i>Conversion Rate</i>
Findings	Business insight yang didapatkan berdasarkan significance testing adalah bahwa jumlah hari dihubungi pada campaign sebelumnya berpengaruh terhadap keinginan nasabah untuk dapat membuka rekening term deposit. Conversion rate terjadi

Amount of contact performed on previous campaign

lebih baik pada *treatment group* yang merupakan data group untuk *customer* yang hari terakhir di kontak pada *campaign* sebelumnya adalah lebih dari 30 hari

Business Recommendation

Business recommendation yang dapat diberikan berdasarkan insight ini untuk meningkatkan conversion rate adalah dengan meningkatkan engagement namun dalam batas per campaign yang tidak terlalu dekat (lebih dari 30 hari). Hal ini dapat menjadi insight dalam rentang waktu optimal membuka campaign baru.



5. Git

Github	<u>tautan</u>
Repository	